Projet final Machine Learning

Etude du papier *Some Properties of Regularized Kernel Methodes.*

De Vito, E., Rosasco, L., Caponnetto, A., Piana, M., Verri, A.

Table des matières

1 Notions élémentaires sur le sous gradient des fonctions convexes. 5

1.1 Sous gradient d'une fonction convexe 5

1.2 Fonction de Nemitski 8

2 Problème de minimisation. 9

2.1 Regularized solutions du problème de minimisation de la fonctionnelle de Tikhonov. 9

2.2 Topologie de la somme directe. 12

2.3 Equivalence des deux problèmes de minimisation. 14

3 Problème d'existence et d'unicité des solutions. 17

Abstract

L'objectif du rapport est d'étudier l'article théorique *Some Properties of Regularized Kernel Methods* et de mieux comprendre les méthodes à noyau régularisant. On s'intéressera à la généralisation des méthodes à noyau régularisant en proposant une analyse unificatrice dans le cadre continu.
Cette formulation plus générale permet de prendre en compte à la fois un espace de fonction pénalisante et un espace d'offset et d'étendre la recherche de risque empirique dans le cadre d'une mesure quelconque, en continu. En séparant correctement risque empirique et risque réel (théorique) et en les reliant dans un même problème.
L'avantage de cette étude est qu'elle permet d'unifier la régression linéaire $Y = \mathbb{R}$ et classification $Y = \{\pm 1\}$ en une même formulation, avec des fonctions de pertes convexes qui ne seront plus nécessairement différentiables. Les solutions s'exprimeront alors à l'aide du sous-gradient, ainsi on rappelera d'abord les notions indispensables sur le sous-gradient que l'on utilisera au cours du rapport.
On montrera ensuite le théorème central qui exprime les solutions du problème de régularisation sous forme de conditions explicites sur le noyau dépendant de l'offset. L'espace produit n'étant pas adapté à l'étude des problèmes de régularisation, n'étant pas un espace de fonctions, on montrera que l'ajout du terme d'offset est en réalité équivalent (dans la plupart des cas) à un problème classique de noyau régularisant sur la somme des espaces Hilbertien des fonctions pénalisantes et de l'offset. Ainsi la régularisation sur l'espace produit ne dépendra que du noyau sur l'espace somme. Ce choix est motivé quand on remarque que le terme à minimiser dans le problème de régularisation n'est pas le couple mais bien la somme.
Enfin on discutera des différents résultats qui assurent effectivement l'existence et l'unicité d'une solution, en s'intéressant en particulier au cas empirique de la classification SVM avec hinge loss.

Introduction

Les problèmes de régularisation à noyau reproduisant sur des données empiriques sont des problèmes classiques. Ils consistent à résoudre le problème suivant

$$\min_{f \in \mathscr{H}} \frac{1}{l} \sum_{i=1}^{l} V(y_i, f(x_i)) + \lambda \|f\|^2_{\mathscr{H}}$$

où $\mathscr{H}$ est un espace de Hilbert à noyau reproduisant sur X l'espace des input, Y l'espace des output qui dépend du type de problème étudié, V est une fonction de perte vérifiant des hypothèses classiques (par exemple une fonction lisse), $S = \{(x_i\,, y_i)\}_{1 \leqslant i \leqslant l}$ est un échantillon du phénomène à étudier, λ est le paramètre de régularisation. C'est le cas que l'on retrouve en pratique.

Cet estimateur est le risque empirique avec un terme de lissage, une première amélioration (c'est plutôt le problème duquel on part en fait) serait d'introduire non plus la mesure empirique de l'échantillon mais la réelle distribution ρ des données, qui sera bien entendu considérée inconnue en analogie à la pratique. Le problème à résoudre devient

$$\min_{f \in \mathscr{H}} \int_{X \times Y} V(y, f(x))\, \mathrm{d}\rho(x, y) + \lambda \|f\|^2_{\mathscr{H}}. \tag{1}$$

Notre objectif est d'étudier la généralisation de ce problème au cas où l'on rajoute un espace d'offset et où la fonction de perte est simplement supposée positive et convexe

$$\min_{(f,g) \in \mathscr{H} \times \mathscr{B}} \int_{X \times Y} V(y, f(x) + g(x))\, \mathrm{d}\rho(x, y) + \lambda \|f\|^2_{\mathscr{H}} \tag{2}$$

où $\mathscr{B}$ est un espace de Hilbert à noyau reproduisant sur X, c'est l'espace des offset.

Le problème de régularisation (1) s'intéresse à minimiser un terme qui représente l'erreur aux données avec un terme de lissage, on veut approximer le mieux possible les données tout en restant le plus lisse possible. Si λ est grand alors la solution sera très régularisé mais moins flexible. Si λ est petit alors la solution cherchera à coller le plus possible aux données sans se soucier de sa régularité. L'espace $\mathscr{H}$ est alors un espace de fonctions pénalisées. Dans le problème de régularisation (2) on décide de rajouter un espace d'offset, c'est à dire de rajouter un espace de fonctions non pénalisées, il intervient dans la minimisation du risque mais ne participe pas au lissage de la solution.

Chapitre 1

Notions élémentaires sur le sous gradient des fonctions convexes.

Dans cette partie nous rappelons les résultats élémentaires sur les sous gradients que nous aurons besoin dans ce rapport. Les résultats et leur démonstration sont adaptés de [ETe] et [ETu].

1.1 Sous gradient d'une fonction convexe

Dans toute cette partie, on suppose que $\mathscr{H}$ est un espace de Banach. On note $\mathscr{H}^*$ le dual de $\mathscr{H}$ et $\langle \cdot, \cdot \rangle_{\mathscr{H}}$ son crochet de dualité. On suppose aussi que $F \colon \mathscr{H} \longrightarrow \mathbb{R} \cup \{+\infty\}$ est une fonction convexe.

Définition 1.1.1 (Sous-gradient)
Soit $v_0 \in \mathscr{H}$ telle que $F(v_0) < +\infty$. Le sous-gradient de F au point v_0 est le sous-ensemble de $\mathscr{H}^*$ définit par

$$\partial F(v_0) = \{w \in \mathscr{H}^* \mid F(v) \geqslant F(v_0) + \langle w, v - v_0 \rangle_{\mathscr{H}} \text{ pour tout } v \in \mathscr{H}\}.$$

Si $F(v_0) = +\infty$ on pose $\partial F(v_0) = \emptyset$.

Remarque 1.1.2
Soit $p \in [1\,; +\infty[$ et q l'xposant conjugué. Il y a un isomorphisme naturel entre $L^p(Z, \rho)^*$ et $L^q(Z, \rho)$ et on définit le crochet de dualité pour $f \in L^p(Z, \rho)$ et $g \in L^q(Z, \rho)$ par

$$\langle g, f \rangle_{L^p(Z,\rho)} = \int_Z g(z) f(z) \, \mathrm{d}\rho(z).$$

Le sous-gradient au point $f_0 \in L^p(Z, \rho)$ est alors

$$\partial F(f_0) = \{g \in L^q(Z, \rho) \mid F(f) \geqslant F(f_0) + \int_Z g(z)(f - f_0)(z) \, \mathrm{d}\rho(z) \text{ pour tout } f \in L^p(Z, \rho)\}.$$

Si on se place dans un espace Hilbertien H, alors d'après le théorème de Riesz, pour tout $w \in H^*$, il existe un unique $u \in H$ tel que $w(v) = \langle u, v \rangle_H$ où $\langle \cdot, \cdot \rangle_H$ est le produit scalaire associé à H. On peut donc identifier $H^* \simeq H$. Le crochet de dualité est alors le produit scalaire sur H : $\langle w, v \rangle_H = \langle u, v \rangle_H$. Le sous-gradient de $v_0 \in H$ est alors

$$\partial F(v_0) = \{u \in H \mid F(v) \geqslant F(v_0) + \langle u, v - v_0 \rangle_H \text{ pour tout } v \in H\}.$$

Remarquons que cette définition est bien cohérente avec le cas $p = q = 2$ où on a bien des espaces de Hilbert. Enfin dans le cas particulier de $\mathbb{R}^d$, on le muniera du produit scalaire canonique $\langle x, y \rangle = {}^t xy$, le sous-gradient est donc

$$\partial F(v_0) = \{u \in \mathbb{R}^d \mid F(v) \geqslant F(v_0) + {}^t u(v - v_0) \text{ pour tout } v \in \mathbb{R}^d\}.$$

Proposition 1.1.3
Si F est différentiable en $v_0 \in \mathscr{H}$ alors $\partial F(v_0) = \{F'(v_0)\}$.

Démonstration. Etape 1 : Montrons que $F'(v_0) \in \partial F(v_0)$.
Soit $\phi(t) = F(v_0 + t(v - v_0))$ pour $t \in [0\,;1]$. La fonction ϕ est dérivable en 0 et $\phi'(0) = \langle F'(v_0), v - v_0\rangle_{\mathscr{H}}$.
De plus ϕ est convexe par convexité de F donc par croissance des pentes

$$\frac{\phi(t) - \phi(0)}{t} \leqslant \phi(1) - \phi(0).$$

En passant à la limite quand t tend vers 0 on obtient $\phi'(0) \leqslant \phi(1) - \phi(0)$ c'est à dire

$$\langle F'(v_0), v - v_0\rangle_{\mathscr{H}} \leqslant F(v) - F(v_0).$$

D'où $F(v) \geqslant F(v_0) + \langle F'(v_0), v - v_0\rangle$ et donc $F'(v_0) \in \partial F(v_0)$.

Etape 2 : Montrons que si $w \in \partial F(v_0)$ alors $w = F'(v_0)$.
On a pour tout $v \in \mathscr{H}$ que $F(v) \geqslant F(v_0) + \langle w, v - v_0\rangle_{\mathscr{H}}$ donc en appliquant à $v = \lambda h + v_0$ pour tout $\lambda > 0$ et tout $h \in \mathscr{H}$ on a $F(v_0 + \lambda h) \geqslant F(v_0) + \langle w, \lambda h\rangle_{\mathscr{H}}$ c'est à dire

$$\frac{F(v_0 + \lambda h) - F(v_0)}{\lambda} \geqslant \langle w, h\rangle_{\mathscr{H}}.$$

En passant à la limite quand λ tend vers 0, comme F est différentiable, on a $\langle F'(v_0), h\rangle \geqslant \langle w, h\rangle$ c'est à dire

$$\langle F'(v_0) - w, h\rangle_{\mathscr{H}} \geqslant 0 \quad \text{pour tout } h \in \mathscr{H}.$$

En appliquant l'inégalité à $-h$ on a aussi

$$\langle F'(v_0) - w, -h\rangle = -\langle F'(v_0) - w, h\rangle \geqslant 0 \text{ pour tout } h \in \mathscr{H}.$$

Ainsi $\forall h \in \mathscr{H}$, $\langle F'(v_0) - w, h\rangle = 0$ donc $F'(v_0) = w$. □

Proposition 1.1.4
Supposons que F soit à variable dans $\mathbb{R}$. Soit $v_0 \in \mathbb{R}$ tel que $F(v_0) < +\infty$ alors $\partial F(v_0) = \big[F'_-(v_0)\,; F'_+(v_0)\big]$.

Démonstration. Etape 1 : Montrons que $\partial F(v_0) \subset \big[F'_-(v_0)\,; F'_+(v_0)\big]$.
Les limites à gauche et à droite existent car F est convexe et finie en ce point. Par définition du sous-gradient on a $F(v) \geqslant F(v_0) + w(v - v_0)$ pour tout $v \in \mathbb{R}$.
Donc pour $v > v_0$, $\dfrac{F(v) - F(v_0)}{v - v_0} \geqslant w$ d'où en passant à la limite en v_0^+, $F'_+(v_0) \geqslant w$.
De même pour $v < v_0$ on a $\dfrac{F(v) - F(v_0)}{v - v_0} \leqslant w$ d'où $F'_-(v_0) \leqslant w$.
Ainsi $\partial F(v_0) \subset \big[F'_-(v_0)\,; F'_+(v_0)\big]$.

Etape 2 : Montrons $\big[F'_-(v_0)\,; F'_+(v_0)\big] \subset \partial F(v_0)$.
Soit $w \in \big[F'_-(v_0)\,; F'_+(v_0)\big]$, posons $\phi(h) = \dfrac{F(v_0 + h) - F(v_0)}{h}$. Par convexité, ϕ est croissante et tend vers $F'_+(v_0)$ quand h tend vers 0^+ et tend vers $F'_-(v_0)$ quand h tend vers 0^-.
Donc si $v > v_0$ alors $\phi(v - v_0) = \dfrac{F(v) - F(v_0)}{v - v_0} \geqslant F'_+(v_0) \geqslant w$ d'où $F(v) \geqslant F(v_0) + w(v - v_0)$. Et si $v < v_0$, $\phi(v - v_0) = \dfrac{F(v) - F(v_0)}{v - v_0} \leqslant F'_-(v_0) \leqslant w$ donc $F(v) \geqslant F(v_0) + w(v - v_0)$ (car $v - v_0 < 0$). Et si $v = v_0$ c'est évident.
Ainsi $\partial F(v_0) = \big[F'_-(v_0)\,; F'_+(v_0)\big]$. □

Proposition 1.1.5
Soit $v_0 \in \mathscr{H}$. Si F est différent de la fonction $+\infty$ alors v_0 est un minimum de F si et seulement si $0 \in \partial F(v_0)$.

Démonstration. Si $0 \in \partial F(v_0)$ alors $F(v) \geqslant F(v_0) + \langle 0, v - v_0 \rangle = F(v_0)$ pour tout $v \in \mathscr{H}$.
Si $F(v) \geqslant F(v_0)$ pour tout $v \in \mathscr{H}$ alors comme F n'est pas identiquement $+\infty$, il existe un point finie et forcément $\partial F(v_0) \neq \emptyset$. Donc $F(v) \geqslant F(v_0) = F(v_0) + \langle 0, v - v_0 \rangle$ d'où $0 \in \partial F(v_0)$. □

Proposition 1.1.6
Supposons que $\mathscr{H}$ est réflexif. Si F est continue et $\lim\limits_{\|v\|_{\mathscr{H}} \to +\infty} F(v) = +\infty$ alors F a un minimum. Si F est strictement convexe le minimum est unique.

Proposition 1.1.7
Soit $G \colon \mathscr{H} \longrightarrow \mathbb{R} \cup \{+\infty\}$ une fonction convexe, soit $v_0 \in \mathscr{H}$ telle que F est finie et continue en v_0 et G est finie en v_0. Soit $a, b > 0$, alors $aF + bG$ est convexe et pour tout $v \in \mathscr{H}$,

$$\partial(aF + bG)(v) = a\partial F(v) + b\partial G(v).$$

Démonstration. Etape 1 : Montrons que pour $a > 0$, $\partial(aF)(v_0) = a\partial F(v_0)$. Soit $x \in \mathscr{H}^*$, on a

$$\begin{aligned} x \in \partial(aF)(v_0) &\iff \forall v \in \mathscr{H},\ aF(v) \geqslant aF(v_0) + \langle x, v - v_0 \rangle_{\mathscr{H}} \\ &\iff \forall v \in \mathscr{H},\ F(v) \geqslant F(v_0) + \langle \frac{x}{a}, v - v_0 \rangle_{\mathscr{H}} \\ &\iff \frac{x}{a} \in \partial F(v_0) \text{ car } a > 0. \end{aligned}$$

Ainsi $\partial(aF)(v_0) = a\partial F(v_0)$.

Etape 2 : Montrons que $\partial F(v_0) + \partial G(v_0) = \partial(F + G)(v_0)$. Le sens direct est évident, montrons le sens indirect.
Soit $u^* \in \partial(F + G)(u)$, alors pour tout $v \in \mathscr{H}$, $F(v) + G(v) \geqslant F(u) + G(u) + \langle u^*, v - u \rangle$. Posons les fonctions

$$\mathscr{F}(v) = F(v) - F(u) - \langle u^*, v - u \rangle \quad \text{et} \quad \mathscr{G} = G(u) - G(v)$$

et les ensembles

$$C_1 = \{(v\,, a) \in \mathscr{H} \times \mathbb{R} \mid \mathscr{F}(v) \leqslant a\} \quad \text{et} \quad C_2 = \{(v\,, a) \in \mathscr{H} \times \mathbb{R} \mid a \leqslant \mathscr{G}(v)\}.$$

Notre objectif va-t-être d'utiliser le théorème de Hahn-Banach (voir [Li] p.160) pour trouver un hyperplan séparateur entre $\mathrm{Int}(C_1)$ et C_2, cet hyperplan sera naturellement notre candidat pour notre sous-gradient. Vérifions alors les hypothèses du théorème.
Soit $(v'\,, a') \in C_1 \cap C_2$, alors $\mathscr{F}(v') \leqslant a' \leqslant \mathscr{G}(v')$. Mais $\mathscr{F}(v') \geqslant \mathscr{G}(v')$ d'où $\mathscr{F}(v') = a = \mathscr{G}(v')$
et $(v'\,, a') \in \{(v\,, a) \mid a = \mathscr{F}(v) = \mathscr{G}(v)\} = \mathrm{Front}(C_1 \cap C_2)$. Ainsi $\mathrm{Int}(C_1) \cap C_2 = \emptyset$.
De plus $\mathscr{F}$ est convexe et $C_1 = \mathrm{epi}(\mathscr{F})$ donc C_1 est convexe et $\mathrm{Int}(C_1)$ est convexe. Et $\mathscr{G}$ est concave et $C_2 = \mathrm{ipo}(\mathscr{G})$ donc C_2 est convexe. Enfin $\mathrm{Int}(C_1)$ est non vide car $\mathscr{F}$ est continue et finie en v_0.
D'après le théorème de Hahn-Banach il existe un hyperplan affine h qui sépare faiblement $\mathrm{Int}(C_1)$ et C_2. C'est à dire qu'il existe $v^* \in \mathscr{H}^*$ et $\alpha \in \mathbb{R}$ telle que

$$\forall v \in \mathscr{H},\ h(v) = \langle v^*, v \rangle + \alpha$$

et telle

$$\forall v \in \mathscr{H},\ \mathscr{G}(v) \leqslant h(v) \leqslant \mathscr{F}(v).$$

En appliquant au point $u \in \mathscr{H}$ on a $h(u) = \langle v^*, u \rangle + \alpha = 0$. En effet $\mathscr{F}(u) = \mathscr{G}(u) = 0$ donc par encadrement

$h(u) = 0$ c'est à dire $\alpha = -\langle v^*, u\rangle$. Donc

$$\forall v \in \mathscr{H},\ G(v) \geqslant G(u) + \langle -v^*, v-u\rangle \quad \text{et} \quad \forall v \in \mathscr{H},\ F(v) \geqslant F(u) + \langle v^* + u^*, v-u\rangle.$$

C'est à dire $-v^* \in \partial G(u)$ et $u^* + v^* \in \partial F(u)$ d'où $u^* = u^* + v^* - v^* \in \partial F(u) + \partial G(u)$. □

Proposition 1.1.8
Soit $\mathscr{H}'$ un autre espace de Banach et $J\colon \mathscr{H}' \longrightarrow \mathscr{H}$ continue et linéaire. Soit $v_0' \in \mathscr{H}'$ tel que F est continue et finie en $J(v_0')$. Alors pour tout $v' \in \mathscr{H}'$

$$\partial F \circ J(v') = J^*(\partial F)(J(v'))$$

où $J^*\colon \mathscr{H}^* \longrightarrow \mathscr{H}'^*$ est l'adjoint de J. C'est à dire $\langle J^*(w), v'\rangle_{\mathscr{H}'} = \langle w, J(v')\rangle_{\mathscr{H}}$ pour $w \in \mathscr{H}^*$ et $v' \in \mathscr{H}'$.

On pose dans la suite de cette partie un espace probabilité $(Z, \mathscr{Z}, \rho)$ où Z est localement compact à base dénombrable.

1.2 Fonction de Nemitski

Définition 1.2.1 (Fonction de Nemitski)
Soit une fonction $W\colon Z\times\mathbb{R} \longrightarrow \mathbb{R}_+$ mesurable. La fonction de Nemitski associée à W est la fonction $I_0\colon L^p(Z,\rho) \longrightarrow \mathbb{R}_+$ définie par

$$I_0(u) = \int_Z W(z, u(z))\,\mathrm{d}\rho(z).$$

Cette définition s'appliquera donc naturellement pour les éléments de $\mathscr{H}$. Qu'on notera parfois sous forme fonctionnelle $I_0(u) := I_0 u$.

Proposition 1.2.2
Soient $p \in [1\,;+\infty[$ et $W\colon Z \times \mathbb{R} \mapsto \mathbb{R}_+$ mesurable telle que $W(z,\cdot)$ est semi-continue inférieurement (l.s.c) ρ-presque partout. Alors la fonction de Nemitski associée à W est l.s.c sur $L^p(Z,\rho)$.

Démonstration. Soit $(x_n)_n \in L^p(Z,\rho)^{\mathbb{N}}$ telle que $x_n \longrightarrow x$ dans $L^p(Z,\rho)$. Par définition de la limite inf il existe une sous suite $(n_k)_{k\in\mathbb{N}}$ telle que

$$\lim_{k\to+\infty} I_0(x_{n_k}) = \liminf_{n\to+\infty} I_0(x_n).$$

Comme $x_{n_k} \longrightarrow x$ dans $L^p(Z,\rho)$ alors la suite converge en probabilité et donc il existe une sous-suite convergente ρ-presque surement, c'est à dire il existe $(n_{k_i})_{i\in\mathbb{N}}$ telle que $\lim\limits_{i\to+\infty} x_{n_{k_i}} \longrightarrow x$ ρ-presque surement.
Comme W est l.s.c ρ-presque partout alors $W(z,u(z)) \leqslant \liminf\limits_{i\to+\infty} W(z, x_{n_{k_i}}(z))$ ρ-presque surement. D'après le lemme de Fatou (W est positive) alors

$$\begin{aligned}\int_Z W(z,x(z))\,\mathrm{d}\rho(z) &\leqslant \int_Z \liminf_{i\to+\infty} W(z, x_{n_{k_i}}(z))\,\mathrm{d}\rho(z)\\ &\leqslant \liminf_{i\to+\infty} \int_Z W(z, x_{n_{k_i}}(z))\,\mathrm{d}\rho_(z).\end{aligned}$$

Ainsi $I_0(x) \leqslant \liminf\limits_{i\to+\infty} I_0(x_{n_{k_i}}) \leqslant \lim\limits_{k\to+\infty} I_0(x_{n_k}) = \liminf\limits_{n\to+\infty} I_0(x_n)$. D'où I_0 est l.s.c. □

Proposition 1.2.3
Soit $W\colon Z \times \mathbb{R} \longrightarrow \mathbb{R}_+$ convexe et l.s.c ρ-presque partout. Soit $u_0 \in L^p(Z,\rho)$ telle que $\sup\limits_{z\in Z}|u_0(z)| < +\infty$ et $I_0(u_0) < +\infty$. Soit $u \in L^p(Z,\rho)$, alors

$$\partial I_0(u) = \{w \in L^q(Z,\rho) \mid w(z) \in \partial W(z,u(z))\rho - a.s\}.$$

Chapitre 2

Problème de minimisation.

2.1 Regularized solutions du problème de minimisation de la fonctionnelle de Tikhonov.

Dans toute la suite on définit l'espace des input X qu'on suppose localement compact et à base dénombrable et l'espace des output Y qu'on suppose être un fermé de $\mathbb{R}$. On définit $\mathscr{H}$ et $\mathscr{B}$ deux Reproducing Kernel Hilbert Space (RKHS) sur X de noyau respectif K et $K^{\mathscr{B}}$. Soit $Z = X \times Y$ et $(Z, \sigma(Z), \rho)$ un espace probabilité où $\sigma(Z)$ la tribu borélienne de Z. On note ρ_X la marginale de ρ sur X.

Définition 2.1.1 (Fonction de perte)
Soit $p \in [1\,;+\infty[$. Une fonction de perte p (p-loss) par rapport à ρ est une fonction $V\colon Y \times \mathbb{R} \longrightarrow \mathbb{R}_+$ telle que

- $\forall y \in Y$, $V(y, \cdot)$ est convexe.
- V est mesurable sur $Y \times \mathbb{R}$.
- Il existe $b \in \mathbb{R}_+$ et $a\colon Y \longrightarrow \mathbb{R}_+$ telle que $V(y, w) \leqslant a(y) + b|w|^p$ et $\displaystyle\int_Z a(y)\,\mathrm{d}\rho(x, y) < +\infty$.

Définition 2.1.2 (Expected risk)
Soit $V\colon Y \times \mathbb{R} \longrightarrow \mathbb{R}_+$ une p-loss et $f\colon X \longrightarrow \mathbb{R}$ mesurable. On définit l'expected risk de f par rapport à V comme

$$I[f] = \int_Z V(y\,, f(x))\,\mathrm{d}\rho(x\,, y).$$

L'expected risk est bien définie car l'intégrande est mesurable et positive.
On définit le risque empirique (empirical risk) de f par rapport V d'un échantillon $\{(x_i\,, y_i)\}_{1\leqslant i\leqslant n}$ comme

$$\tilde{I}[f] = \frac{1}{n}\sum_{i=1}^{n} V(y_i\,, f(x_i)).$$

Le risque empirique correspond à l'expected risk de f par rapport à V sous la probabilité $\tilde{\rho} = \dfrac{1}{n}\displaystyle\sum_{i=1}^{n} \delta_{(x_i, y_i)}$, qui est bien une fonction p-loss par rapport à $\tilde{\rho}$ car c'est une somme finie de Dirac. En effet

$$I[f] = \int_Z V(y\,, f(x))\,\mathrm{d}\tilde{\rho}(x\,, y) = \frac{1}{n}\sum_{i=1}^{n} V(y_i\,, f(x_i)) = \tilde{I}[f].$$

Enfin le problème (1) se réexprime donc sous la forme, c'est la minimisation de la fonctionnelle de Tikhonov,

$$\min_{(f,g)\in\mathscr{H}\times\mathscr{B}} I[f+g] + \lambda\|f\|^2_{\mathscr{H}}. \tag{2.1}$$

Définition 2.1.3

Soit $p \in [1\,;+\infty[$. On dit que le noyau K est p-borné par rapport à ρ si K est mesurable sur Z et

$$\int_Z K(x,x)^{p/2}\,\mathrm{d}\rho(x,y) < +\infty.$$

Proposition 2.1.4
Soit $p \in [1\,;+\infty[$. Supposons que K soit p-borné, on a une inclusion naturelle de $\mathscr{H}$ dans $L^p(Z,\rho)$. L'inclusion est continue et linéaire.

Démonstration. Pour toute fonction $f \in \mathscr{H}$ on définit la fonction $\tilde{f}\colon (x\,,y) \in X \times Y \mapsto f(x) \in \mathbb{R}$ puis l'inclusion $i\colon f \in \mathscr{H} \mapsto \tilde{f} \in \mathbb{R}^Z$.
Montrons que $\tilde{f} \in L^p(Z,\rho)$ c'est à dire $i(\mathscr{H}) \subset L^p(Z,\rho)$.
Soit $f \in \mathscr{H}$, par reproduction on a $f(x) = \langle f, K_x\rangle_{\mathscr{H}}$ donc par Cauchy-Schwarz

$$|f(x)| \leqslant \|f\|_{\mathscr{H}}\|K_x\|_{\mathscr{H}} = \|f\|_{\mathscr{H}}\sqrt{K(x,x)}.$$

Ainsi

$$\begin{aligned}\int_Z \left|\tilde{f}(x,y)\right|^p \mathrm{d}\rho(x,y) &= \int_X |f(x)|^p\,\mathrm{d}\rho_X(x)\\ &\leqslant \|f\|^p_{\mathscr{H}}\int_X K(x,x)^{p/2}\,\mathrm{d}\rho_X(x)\\ &< +\infty \quad \text{car } K \text{ est p-borné.}\end{aligned}$$

Donc $\tilde{f} \in L^p(Z,\rho)$. L'inclusion est linéaire et $\|i\| = \sup\limits_{f\in\mathscr{H}\setminus 0} \dfrac{\|\tilde{f}\|_{L^p(Z,\rho)}}{\|f\|_{\mathscr{H}}} < +\infty$ donc i bornée et finalement i est continue. □

On identifiera dorénavant f et $i(f)$ donc on verra $\mathscr{H}$ comme un sous-ensemble de $L^p(Z,\rho)$ en gardant à l'esprit que l'identification se fait ρ_X-presque partout : deux fonctions de $\mathscr{H}$ égale ρ_X-presque partout seront identifiées.

Proposition 2.1.5
Soit $V\colon Y \times \mathbb{R} \longrightarrow \mathbb{R}_+$ une fonction p-loss. La fonction de Nemitski associé à V est bien définie et continue.

Démonstration. On regarde V comme une fonction de $Z \times \mathbb{R}$: $V((x\,,y),w) = V(y,w)$. La fonction de Nemitski associé à V est bien définie compte tenu des hypothèses d'une fonction p-loss. De plus

$$\begin{aligned}I_0(u) &= \int_Z V(y,u(z))\,\mathrm{d}\rho(x,y)\\ &\leqslant \int_Z a(y) + b|u(z)|^p\,\mathrm{d}\rho(x,y)\\ &< +\infty.\end{aligned}$$

Donc $I_0(u)$ est finie. Comme V est positive et $V(z,\cdot)$ est convexe finie sur $\mathbb{R}$ donc continue donc l.s.c alors d'après 1.2.2 I_0 est l.s.c.
Soit $g(z,w) = a(z) + b|w|^p - V(z,w)$, on a g positive et $w \mapsto g(z,w)$ continue donc l.s.c ainsi la fonction de Nemitski associé à g que l'on notera $\tilde{I}_0$ est bien définie. $\tilde{I}_0$ est l.s.c. Or

$$\tilde{I}_0 u = \int_Z a(z)\,\mathrm{d}\rho(z) + b\int_Z |u(z)|^p\,\mathrm{d}\rho(z) - I_0 u = c + b\|u\|^p_{L^p(Z,\rho)} - I_0 u$$

avec $c \in \mathbb{R}$ une constante. Donc

$$I_0 u = \underbrace{c + b\|u\|^p_{L^p(Z,\rho)}}_{\text{continue}}\underbrace{-\tilde{I}_0 u}_{u.s.c}.$$

Ainsi I_0 est semi-continue supérieurement (u.s.c) et l.s.c donc elle est continue sur $L^p(Z,\rho)$. □

Remarque 2.1.6
Ainsi sous les hypothèses de $V\colon Y \times \mathbb{R} \longrightarrow \mathbb{R}_+$ une fonction p-loss et K p-borné pour $p \in [1\,;+\infty[$ on pourra identifié l'expected risk de f par rapport à V : $I[f]$ et la fonction de Nemitski associé à V appliqué à f : $I_0 f$. C'est ce qu'on fera toujours dorénavant. Dans ce cadre le problème (2.1) se réexprime sous la forme (avec $K^{\mathscr{B}}$ p-borné)

$$\min_{(f,g)\in\mathscr{H}\times\mathscr{B}} I_0(f+g) + \lambda\|f\|^2_{\mathscr{H}}.$$

Proposition 2.1.7
Supposons que K et $K^{\mathscr{B}}$ sont p-bornés. L'opérateur $J\colon \begin{array}{ccc} \mathscr{H}\times\mathscr{B} & \longrightarrow & L^p(Z,\rho) \\ (f\,,g) & \mapsto & f+g \end{array}$ est bien définie et continue.

Démonstration. La démonstration a partiellement déjà été faites propriété 2.1.4, on a $\|f\|_{L^p(Z,\rho)} \leqslant C\|f\|_{\mathscr{H}}$ et $\|g\|_{L^p(Z,\rho)} \leqslant D\|g\|_{\mathscr{B}}$ car K et $K^{\mathscr{B}}$ sont p-bornés donc $\|J(f,g)\|_{L^p(Z,\rho)} \leqslant C\|f\|_{\mathscr{H}} + D\|g\|_{\mathscr{B}} \leqslant (C+D)\|(f\,,g)\|_{\mathscr{H}\times\mathscr{B}}$. D'où J est linéaire et bornée donc continue. □

Remarque 2.1.8
On poursuit les remarques fait en 1.1.2. On rappelle que l'espace produit $\mathscr{H}\times\mathscr{B}$ est un espace Hilbertien muni du produit scalaire $\langle(\phi\,,\varphi),(f\,,g)\rangle_{\mathscr{H}\times\mathscr{B}} = \langle\phi,f\rangle_{\mathscr{H}} + \langle\varphi,g\rangle_{\mathscr{B}}$. Ainsi le crochet de dualité se définit comme le produit scalaire sur $\mathscr{H}\times\mathscr{B}$.

Théorème 2.1.9
Soient $(f\,,g) \in \mathscr{H}\times\mathscr{B}$ et $(\phi\,,\varphi) \in \mathscr{H}\times\mathscr{B}$. Alors $(\phi\,,\varphi) \in \partial(I_0\circ J)(f\,,g)$ si et seulement si il existe $\alpha \in L^q(Z,\rho)$ telle que

- $\alpha(x,y) \in \partial V(y, f(x)+g(x))$ pour ρ-presque tout $(x\,,y) \in Z$.
- $\phi(s) = \displaystyle\int_Z K(s,x)\alpha(x,y)\,\mathrm{d}\rho(x,y)$ pour $s \in X$.
- $\varphi(s) = \displaystyle\int_Z K^{\mathscr{B}}(s,x)\alpha(x,y)\,\mathrm{d}\rho(x,y)$ pour $s \in X$.

Démonstration. Comme I_0 est finie et continue en $0 = J(0)$ d'après 2.1.5 et que J est linéaire et continue d'après 2.1.7 alors d'après la proposition 1.1.8,

$$\partial(I_0\circ J)(f\,,g) = J^*(\partial I_0)(J(f,g))$$

où $J^*\colon L^q(Z,\rho) \longrightarrow \mathscr{H}\times\mathscr{B}$ est telle que

$$\langle J^*\alpha,(f\,,g)\rangle_{\mathscr{H}\times\mathscr{B}} = \int_Z \alpha(x,y)J(f,g)(x,y)\,\mathrm{d}\rho(x,y).$$

Donc $(\phi\,,\varphi) \in \partial(I_0\circ J)(f\,,g)$ si et seulement si il existe $\alpha \in \partial I_0(J(f\,,g))$ telle que $(\phi\,,\varphi) = J^*\alpha$.
Calculons l'adjoint de J au point α. Par reproduction

$$\phi(s) = \langle\phi,K_s\rangle_{\mathscr{H}} = \langle J^*\alpha,(K_s\,,0)\rangle_{\mathscr{H}\times\mathscr{B}} = \langle\alpha,J(K_s,0)\rangle_{L^p(Z,\rho)} = \int_Z K(s,x)\alpha(x,y)\,\mathrm{d}\rho(x,y).$$

De même

$$\varphi(s) = \int_Z K^{\mathscr{B}}(s,x)\alpha(x,y)\,\mathrm{d}\rho(x,y).$$

Les intégrales sont bien définie par les inégalités de Holder.
Enfin on a $I_0(0) < +\infty$ (et $\sup|0| = 0$...) donc d'après 1.2.3, $\alpha \in \partial I_0(J(f\,,g))$ si et seulement si $\alpha \in L^q(Z,\rho)$ et $\alpha(x\,,y) \in \partial V(y, J(f\,,g)(x\,,y)) = \partial V(y, f(x)+g(x))$ ρ-presque partout.
D'où le résultat final en rassemblant tous les résultats. □

Théorème 2.1.10
Soit V une fonction de perte p par rapport à ρ avec $p \in [1\,;+\infty[$. Supposons K et $K^{\mathscr{B}}$ p-borné par rapport à ρ

et soit $\lambda > 0$. Alors

$$(f^\lambda\,, g^\lambda) \in \operatorname{argmin}_{(f,g)\in\mathscr{H}\times\mathscr{B}} \int_Z V(y, f(x) + g(x))\,\mathrm{d}\rho(x,y) + \lambda\|f\|^2_{\mathscr{H}}$$

si et seulement si il existe $\alpha \in L^q(Z,\rho)$ telle que

- $\alpha(x,y) \in \partial V(y, f^\lambda(x) + g^\lambda(x))$ pour ρ-presque tout $(x,y) \in X \times Y$.
- $f^\lambda(s) = -\dfrac{1}{2\lambda}\displaystyle\int_Z K(s,x)\alpha(x,y)\,\mathrm{d}\rho(x,y)$ pour $s \in X$.
- $0 = \displaystyle\int_Z K^{\mathscr{B}}(s,x)\alpha(x,y)\,\mathrm{d}\rho(x,y)$ pour $s \in X$.

Démonstration. Notons déjà que le problème de minimisation correspond au problème de minimisation de (2.1). D'après la proposition 1.1.5, $(f^\lambda\,, g^\lambda)$ est un minimum de $I[f+g] + \lambda\|f\|^2_{\mathscr{H}}$ si et seulement si

$$(0\,,0) \in \partial(I_0 \circ J + \lambda\|\cdot\|^2_{\mathscr{H}})(f^\lambda\,, g^\lambda). \tag{2.2}$$

Or la fonction $\lambda\|\cdot\|^2_{\mathscr{H}}$ est continue et la fonction $I_0 \circ J$ est continue et finie donc d'après 1.1.7,

$$\partial(I_0 \circ J + \lambda\|\cdot\|^2_{\mathscr{H}}) = \partial(I_0 \circ J) + \lambda\partial(\|\cdot\|^2_{\mathscr{H}}).$$

La fonction $(f\,,g) \mapsto \|f\|^2_{\mathscr{H}}$ est différentiable de dérivée $(2f\,,0)$ donc $\partial(\|\cdot\|^2_{\mathscr{H}})(f^\lambda) = \{(2f^\lambda\,,0)\}$ par la proposition 1.1.3. D'où on a (2.2) si et seulement si

$$(0\,,0) = (\phi + 2\lambda f^\lambda\,, \varphi) \text{ avec } (\phi\,,\varphi) \in \partial(I_0 \circ J)(f^\lambda\,, g^\lambda).$$

Et d'après le théorème 2.1.9 $(\phi\,,\varphi) \in \partial(I_0 \circ J)(f^\lambda\,, g^\lambda)$ si et seulement si

$$\phi = \int_Z K(x,\cdot)\alpha(x,y)\,\mathrm{d}\rho(x,y) \quad \text{ et } \quad \varphi = \int_Z K^{\mathscr{B}}(x,\cdot)\alpha(x,y)\,\mathrm{d}\rho(x,y)$$

où $\alpha \in L^q(Z,\rho)$ est telle que $\alpha(x,y) \in \partial V(y, f^\lambda(x) + g^\lambda(x))$ ρ-presque partout. En combinant les deux expressions on a finalement le résultat. □

Corollaire 2.1.11
Soit V une fonction de perte p par rapport à ρ avec $p \in [1\,;+\infty[$. Supposons K p-borné par rapport à ρ et soit $\lambda > 0$. Alors

$$f^\lambda \in \operatorname{argmin}_{f\in\mathscr{H}} \int_Z V(y, f(x))\,\mathrm{d}\rho(x,y) + \lambda\|f\|^2_{\mathscr{H}}$$

si et seulement si il existe $\alpha \in L^q(Z,\rho)$ telle que

- $\alpha(x,y) \in \partial V(y, f^\lambda(x))$ pour ρ-presque tout $(x,y) \in X \times Y$.
- $f^\lambda(s) = -\dfrac{1}{2\lambda}\displaystyle\int_Z K(s,x)\alpha(x,y)\,\mathrm{d}\rho(x,y)$ pour $s \in X$.

Démonstration. Il suffit juste d'appliquer le théorème 2.1.10 à l'espace Hilbertien $\mathscr{H} \simeq \mathscr{H} \times \{0\}$. □

2.2 Topologie de la somme directe.

On pose l'espace Hilbertien $\mathscr{S} = \mathscr{H} + \mathscr{B}$ muni de la norme (et donc du produit scalaire associé)

$$\|f+g\|^2_{\mathscr{S}} = \inf_{\substack{f'\in\mathscr{H} \quad g'\in\mathscr{B} \\ f'+g'=f+g}} (\|f'\|^2_{\mathscr{H}} + \|g'\|^2_{\mathscr{B}}).$$

C'est en particulier un RKHS avec comme noyau reproduisant $K + K^{\mathscr{B}}$.
Soient

$$\mathscr{S}_0 = \{s \in \mathscr{S} \mid \langle s, g\rangle_{\mathscr{S}} = 0 \quad \forall g \in \mathscr{B}\} = \mathscr{B}^{\perp} \quad \text{et} \quad \mathscr{H}_0 = \{f \in \mathscr{H} \mid \langle f, h\rangle_{\mathscr{H}} = 0 \quad \forall h \in \mathscr{H} \cap \mathscr{B}\} = (\mathscr{H} \cap \mathscr{B})^{\perp}$$

les orthogonaux dans $\mathscr{S}$ et $\mathscr{H}$ avec Q la projection orthogonale de $\mathscr{S}$ sur $\mathscr{S}_0$ et P la projection orthogonale de $\mathscr{H}$ sur $\mathscr{H}_0$. Les projections sont bien définies car ce sont des sous-espaces vectoriels fermés (des espaces orthogonaux).

Proposition 2.2.1
Soit $s \in \mathscr{S}$ et soit l'ensemble

$$K = \{(f\,, g) \in \mathscr{H} \times \mathscr{B} \mid \langle f, h\rangle_{\mathscr{H}} = \langle g, h\rangle_{\mathscr{B}} \quad \forall h \in \mathscr{H} \cap \mathscr{B}\}$$

alors il existe un unique $(f\,, g) \in K$ telle que $s = f + g$.
On dira que $(f\,, g)$ est la représentation de s.

Démonstration. Soit $(f\,, g) \in \mathscr{H} \times \mathscr{B}$,

$$\begin{aligned}(f\,, g) \in K &\iff \forall h \in \mathscr{H} \cap \mathscr{B},\ \langle (f\,, g), (h\,, -h)\rangle_{\mathscr{H}\times\mathscr{B}} = 0 \\ &\iff K = N^{\perp} \text{ dans } \mathscr{H} \times \mathscr{B} \text{ où } N = \{(h\,, -h) \mid h \in \mathscr{H} \cap \mathscr{B}\}.\end{aligned}$$

Comme $\mathscr{H} \times \mathscr{B}$ est un Hilbert et N un fermé on a $\mathscr{H} \times \mathscr{B} = N \oplus N^{\perp}$ donc pour tout $(f_0\,, g_0) \in \mathscr{H} \times \mathscr{B}$ il existe un unique $(f\,, g) \in K$ et un unique $h \in \mathscr{H} \cap \mathscr{B}$ telle que $(f_0\,, g_0) = (f\,, g) + (h\,, -h)$ c'est à dire $f_0 + g_0 = f + g$. □

Proposition 2.2.2
Soit $s \in \mathscr{S}$ tel que $s = f + g$ avec $(f\,, g) \in K$, alors $\|s\|^2_{\mathscr{S}} = \|f\|^2_{\mathscr{H}} + \|g\|^2_{\mathscr{B}}$. C'est à dire que la borne inférieur est un minimum atteint sur K. De plus ce minimum est unique.

Démonstration. Soit $s = f+g$ avec $(f\,, g) \in K$ (on sait d'après 2.2.1 que ce couple existe toujours et est unique). Soit $(f'\,, g') \in \mathscr{H} \times \mathscr{B}$ telle que $s = f' + g'$. Alors $f' - f = g - g' \in \mathscr{H} \cap \mathscr{B}$. D'où $f' = f + h$ et $g' = g - h$ avec $h = f' - f \in \mathscr{H} \cap \mathscr{B}$. Ainsi

$$\begin{aligned}\|f'\|^2_{\mathscr{H}} + \|g'\|^2_{\mathscr{B}} &= \|f\|^2_{\mathscr{H}} + \|h\|^2_{\mathscr{H}} + \|g\|^2_{\mathscr{B}} + \|h\|^2_{\mathscr{B}} + 2\langle f, h\rangle_{\mathscr{H}} - 2\langle g, h\rangle_{\mathscr{B}} \\ &= \|f\|^2_{\mathscr{H}} + \|h\|^2_{\mathscr{H}} + \|g\|^2_{\mathscr{B}} + \|h\|^2_{\mathscr{B}} \\ &\geqslant \|f\|^2_{\mathscr{H}} + \|g\|^2_{\mathscr{B}}\end{aligned}$$

car $\langle f, h\rangle_{\mathscr{H}} = \langle g, h\rangle_{\mathscr{B}}$ car $h \in \mathscr{H} \cap \mathscr{B}$. Ainsi $(f\,, g)$ est un minimum et $\|f + g\|^2_{\mathscr{S}} = \|f\|^2_{\mathscr{H}} + \|g\|^2_{\mathscr{B}}$.
Si on a un autre minimum alors $\|h\|^2_{\mathscr{H}} + \|h\|^2_{\mathscr{B}} = 0$ c'est à dire $h = f - f' = g' - g = 0$ donc le minimum est unique. □

Lemme 2.2.3
Soit $s, s' \in \mathscr{S}$ de représentation respectives $(f\,, g)$ et $(f'\,, g')$. Alors

$$\langle s, s'\rangle_{\mathscr{S}} = \langle f, f'\rangle_{\mathscr{H}} + \langle g, g'\rangle_{\mathscr{B}}.$$

Démonstration. Par simple calcul on vérifie que $(f + f'\,, g + g')$ est la représentation de $s + s'$ et $(f - f'\,, g - g')$ est la représentation de $s - s'$.

Donc d'après la formule de polarisation

$$\begin{aligned}
\langle s, s'\rangle_{\mathscr{S}} &= \frac{1}{4}(\|s+s'\|^2_{\mathscr{S}} - \|s-s'\|^2_{\mathscr{S}}) \\
&= \frac{1}{4}(\|f+f'\|^2_{\mathscr{H}} + \|g+g'\|^2_{\mathscr{B}} - \|f-f'\|^2_{\mathscr{H}} - \|g-g'\|^2_{\mathscr{B}}) \\
&= \frac{1}{4}(\|f\|^2_{\mathscr{H}} + \|f'\|^2_{\mathscr{H}} + 2\langle f, f'\rangle_{\mathscr{H}} + \|g\|^2_{\mathscr{B}} + \|g'\|^2_{\mathscr{B}} + 2\langle g, g'\rangle_{\mathscr{B}} \\
&\qquad\qquad - \|f\|^2_{\mathscr{H}} - \|f'\|^2_{\mathscr{H}} + 2\langle f, f'\rangle_{\mathscr{H}} - \|g\|^2_{\mathscr{B}} - \|g'\|^2_{\mathscr{B}} + 2\langle g, g'\rangle_{\mathscr{B}} \\
&= \frac{1}{4}(4\langle f, f'\rangle_{\mathscr{H}} + 4\langle g, g'\rangle_{\mathscr{B}}) \\
&= \langle f, f'\rangle_{\mathscr{H}} + \langle g, g'\rangle_{\mathscr{B}}.
\end{aligned}$$

□

Proposition 2.2.4
Soit $s \in \mathscr{S}$ de représentation $(f\,, g)$ et $s' \in \mathscr{S}$. Le produit scalaire de s et s' ne dépend pas de la décomposition de s'.

Démonstration. Montrons qu'en réalité on peut prendre n'importe quel représentant pour s'. Soit $s' = f'_1 + g'_1 = f'_2 + g'_2$. Alors

$$\begin{aligned}
\langle f, f'_1\rangle_{\mathscr{H}} + \langle g, g'_1\rangle_{\mathscr{B}} &= \langle f, f'_1 - f'_2 + f'_2\rangle_{\mathscr{H}} + \langle g, g'_1\rangle_{\mathscr{B}} \\
&= \langle f, f'_2\rangle_{\mathscr{H}} + \langle f, f'_1 - f'_2\rangle_{\mathscr{H}} + \langle g, g'_1\rangle_{\mathscr{B}} \\
&= \langle f, f'_2\rangle_{\mathscr{H}} + \langle g, g'_2 - g'_1\rangle_{\mathscr{B}} + \langle g, g'_1\rangle_{\mathscr{B}} \\
&= \langle f, f'_2\rangle_{\mathscr{H}} + \langle g, g'_2\rangle_{\mathscr{B}}
\end{aligned}$$

car $f'_1 - f'_2 = g'_2 - g'_1 \in \mathscr{H} \cap \mathscr{B}$.
Ainsi le produit scalaire ne dépend pas du représentant pour s' et $\langle s, s'\rangle_{\mathscr{S}} = \langle f, f'_1\rangle_{\mathscr{H}} + \langle g, g'_1\rangle_{\mathscr{B}} = \langle f, f'_2\rangle_{\mathscr{H}} + \langle g, g'_2\rangle_{\mathscr{B}}$. □

Lemme 2.2.5
Soit $f \in \mathscr{H}$. Alors on a $\|f\|_{\mathscr{S}} \leqslant \|f\|_{\mathscr{H}}$ avec égalité des normes sur $\mathscr{H}_0$.

Démonstration. On a

$$\|f\|^2_{\mathscr{S}} = \inf_{\substack{(\tilde{f}, g) \in \mathscr{H} \times \mathscr{B} \\ \tilde{f} + g = f}} (\|\tilde{f}\|^2_{\mathscr{H}} + \|g\|^2_{\mathscr{B}}) \leqslant \|f\|^2_{\mathscr{H}} + \|0\|^2_{\mathscr{B}} = \|f\|^2_{\mathscr{H}}.$$

D'où $\|f\|_{\mathscr{S}} \leqslant \|f\|_{\mathscr{H}}$. De plus si $f \in \mathscr{H}_0$, alors $(f\,, 0)$ est la représentation de f et donc

$$\|f\|^2_{\mathscr{S}} = \langle f + 0, f + 0\rangle_{\mathscr{S}} = \langle f, f\rangle_{\mathscr{H}} = \|f\|^2_{\mathscr{H}}$$

d'où l'égalité des normes sur $\mathscr{H}_0$.
Notons bien que la démonstration de l'égalité des normes ne marche que parce que $(f\,, 0)$ est une représentation de f, ce qui n'est vrai que sur $\mathscr{H}_0$! □

2.3 Equivalence des deux problèmes de minimisation.

Proposition 2.3.1
Soit $s = f + g \in \mathscr{S}$ avec $(f\,, g) \in \mathscr{H} \times \mathscr{B}$ alors

- $Qs = Pf$.
- $\|Qs\|_{\mathscr{S}} = \|Pf\|_{\mathscr{H}}$.

- Il existe une suite $(f_n\,,g_n) \in (\mathscr{H} \times \mathscr{B}^{\mathbb{N}})$ telle que $\lim\limits_n \|Pf - f_n\|_{\mathscr{H}} = 0$ et $f_n + g_n = s$.

Notons que le résultat implique que la projection de f ne dépend pas de la décomposition de s.

Démonstration. Montrons que $\mathscr{H}_0 \subset \mathscr{S}_0$. Si $f \in \mathscr{H}_0$ alors $(f\,,0)$ est la représentation de f donc pour tout $g' \in \mathscr{B}$,

$$\langle (f\,,0),(0\,,g')\rangle_{\mathscr{S}} = \langle f,0\rangle_{\mathscr{H}} + \langle 0,g'\rangle_{\mathscr{B}} = 0$$

donc $f \in \mathscr{S}_0$.
Soit $s = f + g$, on a $f = Pf + h$ avec $h \in \mathscr{H}_0^{\perp} = ((\mathscr{H} \cap \mathscr{B})^{\perp})^{\perp} = \overline{\mathscr{H} \cap \mathscr{B}}$ donc il existe $(h_n) \in \mathscr{H} \cap \mathscr{B}^{\mathbb{N}}$ telle que $\|h_n - h\|_{\mathscr{H}} \longrightarrow 0$.
Mais d'après le lemme 2.2.5 $\|h - h_n\|_{\mathscr{S}} \leqslant \|h - h_n\|_{\mathscr{H}}$ donc $h_n \longrightarrow h$ pour $\|\cdot\|_{\mathscr{S}}$ et comme Q est continue sur $\mathscr{S}$ on a $Qh_n \longrightarrow Qh$ pour $\|\cdot\|_{\mathscr{S}}$.
De plus $\mathscr{S}_0 = \mathscr{B}^{\perp}$ donc $\mathscr{S}_0^{\perp} = \overline{\mathscr{B}}$ c'est à dire $\mathscr{B} \subset \mathscr{S}_0^{\perp}$ donc $Qh_n = 0$ pour tout $n \in \mathbb{N}$ car $h_n \in \mathscr{B}$. Ainsi $Qh = 0$.
En recombinant tous les résultats,

$$Qs = Q(Pf + h + g) = QPf + Qh + Qg = Pf$$

car $g \in \mathscr{B}$ donc $Qg = 0$ et $Pf \in \mathscr{H}_0 \subset \mathscr{S}_0$ et Q est la projection sur $\mathscr{S}_0$. Donc $\|Qs\|_{\mathscr{S}} = \|Pf\|_{\mathscr{S}} = \|Pf\|_{\mathscr{H}}$ d'après le lemme 2.2.5 car on est sur $\mathscr{H}_0$.
Soit $f_n = Pf + h - h_n$ et $g_n = g + h_n$ alors $f_n \in \mathscr{H}$, $g_n \in \mathscr{B}$, $f_n + g_n = f + g = s$ et $\lim\limits_n \|Pf - f_n\|_{\mathscr{H}} = 0$. □

Corollaire 2.3.2
On a $\mathscr{H}_0 = \mathscr{S}_0$.

Démonstration. On sait déjà que $\mathscr{H}_0 \subset \mathscr{S}_0$. Soit $s = f + g \in \mathscr{S}_0$, on a $s = Qs = Pf \in \mathscr{H}_0$ donc $\mathscr{H}_0 = \mathscr{S}_0$ car Q est la projection sur $\mathscr{S}_0$ et d'après la proposition 2.3.1. □

Théorème 2.3.3
Soit V une fonction de perte p par rapport à ρ avec $p \in [1\,;+\infty[$. Supposons K et $K^{\mathscr{B}}$ p-borné par rapport à ρ et soit $\lambda > 0$.
Soit $(f^\lambda\,,g^\lambda) \in \mathscr{H} \times \mathscr{B}$, si $(f^\lambda\,,g^\lambda) \in \operatorname{argmin}_{(f,g)\in\mathscr{H}\times\mathscr{B}}\{I[f+g] + \lambda\|f\|^2_{\mathscr{H}}\}$ alors

$$s^\lambda := f^\lambda + g^\lambda \in \operatorname{argmin}_{s\in\mathscr{S}}\{I[s] + \lambda\|Qs\|^2_{\mathscr{S}}\} \quad \text{et} \quad f^\lambda = Qs^\lambda.$$

Soit $s^\lambda \in \mathscr{S}$, si $s^\lambda \in \operatorname{argmin}_{s\in\mathscr{S}}\{I[s] + \lambda\|Qs\|^2_{\mathscr{S}}\}$ alors avec $f^\lambda = Qs^\lambda$ et $g^\lambda = s^\lambda - Qs^\lambda$ on a

$$I[f^\lambda + g^\lambda] + \lambda\|f^\lambda\|^2_{\mathscr{H}} = \inf_{(f,g)\in\mathscr{H}\times\mathscr{B}}\{I[f+g] + \lambda\|f\|^2_{\mathscr{H}}\}.$$

En particulier si $g^\lambda \in \mathscr{B}$ alors

$$(f^\lambda\,,g^\lambda) \in \operatorname{argmin}_{(f,g)\in\mathscr{H}\times\mathscr{B}}\{I[f+g] + \lambda\|f\|^2_{\mathscr{H}}\}.$$

Démonstration. Soit $s = f + g$, d'après la proposition 2.3.1 il existe $(f_n\,,g_n) \in (\mathscr{H} \times \mathscr{B})^{\mathbb{N}}$ tel que $s = f_n + g_n$ et $\|Pf - f_n\|_{\mathscr{H}} = 0$. Ainsi

$$I_0 s + \lambda\|Qs\|^2_{\mathscr{S}} = I_0 s + \lambda\|Pf\|^2_{\mathscr{H}} = \lim_n I_0 s + \lambda\|f_n\|^2_{\mathscr{H}}.$$

Soit (f^λ, g^λ) un minimum de $I_0 \circ J + \lambda\|\cdot\|^2_{\mathscr{H}}$ et $s^\lambda = f^\lambda + g^\lambda$ alors

$$\begin{aligned} I_0 s^\lambda + \lambda\|f^\lambda\|^2_{\mathscr{H}} &= I_0(f^\lambda + g^\lambda) + \lambda\|f^\lambda\|^2_{\mathscr{H}} \\ &\leqslant I_0(f_n + g_n) + \lambda\|f_n\|^2_{\mathscr{H}} \\ &= I_0 s + \|f_n\|^2_{\mathscr{H}} \\ I_0 s^\lambda + \lambda\|f^\lambda\|^2_{\mathscr{H}} &\leqslant I_0 s + \lambda\|Qs\|^2_{\mathscr{S}} \text{ en passant à la limite.} \end{aligned}$$

Donc en appliquant à la fonction s^λ, $I_0 s^\lambda + \lambda\|Qs^\lambda\|^2_{\mathscr{S}} \geqslant I_0 s^\lambda + \lambda\|f^\lambda\|^2_{\mathscr{H}}$ c'est à dire

$$\|Qs^\lambda\|_{\mathscr{S}} = \|Pf^\lambda\|_{\mathscr{H}} \geqslant \|f^\lambda\|_{\mathscr{H}}.$$

Mais comme $\|Pf\|_{\mathscr{H}} \leqslant \|f\|_{\mathscr{H}}$ car P est une projection et qu'elle est 1-Lipschitz alors $\|Pf^\lambda\|_{\mathscr{H}} = \|f^\lambda\|_{\mathscr{H}}$. Et comme P est la projection orthogonale cela implique $Qs^\lambda = Pf^\lambda = f^\lambda$. D'où

$$I_0 s + \lambda\|Qs\|^2_{\mathscr{S}} \geqslant I_0 s^\lambda + \lambda\left\|Qs^\lambda\right\|^2_{\mathscr{S}}$$

et c'est un minimum.
Soient maintenant s^λ un minimum de $I_0 + \lambda\|Q\cdot\|^2_{\mathscr{S}}$, on pose $f^\lambda = Qs^\lambda$ et $g^\lambda = s^\lambda - f^\lambda$. On a $f^\lambda \in \mathscr{S}_0 = \mathscr{H}_0$ d'après le corollaire 2.3.2 donc $\|Qs^\lambda\|_{\mathscr{S}} = \|f^\lambda\|_{\mathscr{S}} = \|f\|_{\mathscr{H}}$ d'après le lemme 2.2.5. Par définition de s^λ, on a

$$\begin{aligned} I_0 s^\lambda + \lambda\|Qs^\lambda\|^2_{\mathscr{S}} &\leqslant I_0 s + \lambda\|Qs\|^2_{\mathscr{S}} \text{ pour tout } s \in \mathscr{S} \\ &\leqslant \inf_{(f,g)\in\mathscr{H}\times\mathscr{B}} I_0(f+g) + \lambda\|f\|^2_{\mathscr{H}} \end{aligned}$$

$I[f^\lambda + g^\lambda] + \lambda\left\|f^\lambda\right\|_{\mathscr{H}} \leqslant \inf_{(f,g)\in\mathscr{H}\times\mathscr{B}} I[f+g] + \lambda\|f\|^2_{\mathscr{H}}$. En appliquant $I[s] + \lambda\|Qs\|^2_{\mathscr{S}} = \lim_n I[f_n + g_n] + \lambda\|f_n\|^2_{\mathscr{H}}$ à $s^\lambda = f^\lambda + g^\lambda$ on a $I[f^\lambda + g^\lambda] + \lambda\left\|f^\lambda\right\|^2_{\mathscr{H}} = \lim I[f^\lambda_n + g^\lambda_n] + \lambda\left\|f^\lambda_n\right\|^2_{\mathscr{H}}$ $(f_n, g_n) \in \mathscr{H} \times \mathscr{B} \geqslant \inf_{(f,g)\in\mathscr{H}\times\mathscr{B}} I[f + g] + \lambda\left\|f^\lambda\right\|^2_{\mathscr{H}} = \inf_{(f,g)\in\mathscr{H}\times\mathscr{B}} I[f+g] + \lambda\left\|f^\lambda\right\|^2_{\mathscr{H}}$. Ainsi $I[f^\lambda + g^\lambda] + \lambda\left\|f^\lambda\right\|^2_{\mathscr{H}}$ est l'infinimum et si $g^\lambda \in \mathscr{B}$ alors (f^λ, g^λ) est un minimum. $\square$

Chapitre 3

Problème d'existence et d'unicité des solutions.

Proposition 3.0.1 (Existence et unicité quand il n'y a pas d'offset)
Soit V une fonction de perte p par rapport à ρ avec $p \in [1\,;+\infty[$. Supposons K p-borné par rapport à ρ et soit $\lambda > 0$.
Il existe une unique solution au problème $\min\limits_{f\in\mathscr{H}} I[f] + \lambda\|f\|^2_{\mathscr{H}}$.

Démonstration. La fonction $I[\cdot] + \lambda\|\cdot\|^2_{\mathscr{H}}$ est strictement convexe et continue et

$$I[f] + \lambda\|f\|^2_{\mathscr{H}} \geqslant \lambda\|f\|^2_{\mathscr{H}} \underset{\|f\|_{\mathscr{H}}\to+\infty}{\longrightarrow} +\infty$$

d'où l'existence et l'unicité par la proposition 1.1.6. □

Théorème 3.0.2
Soit V une fonction p-loss qui satisfait les conditions suivantes et K p-borné.

- $\lim\limits_{w\to-\infty} V(1,w) = \lim\limits_{w\to+\infty} V(-1,w) = +\infty$.
- Il existe $C > 0$ telle que $\sqrt{K(x,x)} \leqslant C$ pour $x \in \mathrm{supp}\rho_X$.
- $\rho(X \times \{1\} > 0)$ et $\rho(X \times \{-1\}) > 0$.

Alors il existe au moins une solution au problème $\min\limits_{s\in\mathscr{S}} I[s] + \lambda\|Qs\|^2_{\mathscr{S}}$ où $\mathscr{S} = \mathscr{H} + \mathbb{R}$, c'est à dire que $\mathscr{B}$ est l'ensemble des fonctions constantes.

Démonstration. On va montrer que $I[s] + \lambda\|Qs\|^2_{\mathscr{S}} \underset{\|s\|_{\mathscr{S}}\to+\infty}{\longrightarrow} +\infty$. La démonstration de [DV] est un peu obscur sur la raison du choix des bornes, on va structurer la démonstration de manière plus pédagogique pour voir comment elles apparaissent naturellement.

Soit $M > 0$. Soit $R > 0$ (qui dépend de M) tel que $\|s\|_{\mathscr{S}} \geqslant R$. Notre objectif est de déterminer la valeur de R pour que $I[s] + \lambda\|Qs\|^2_{\mathscr{S}} \geqslant M$.

Il existe $r > 0$ tel que $\forall w \leqslant -r$, $V(1,w) \geqslant \dfrac{M}{\alpha}$ et $\forall w \geqslant r$, $V(-1,w) \geqslant \dfrac{M}{\alpha}$. Avec $\alpha = \min(\rho(X \times \{1\} > 0)\,, \rho(X \times \{-1\} > 0)) > 0$.
Ainsi si $s(x) \geqslant r$ pour tout $x \in X$,

$$I[s] = \int_Z V(y, s(x))\,\mathrm{d}\rho(x,y) \geqslant \int_{X\times\{-1\}} v(-1, s(x))\,\mathrm{d}\rho(x,-1) \geqslant \frac{M}{\alpha}\rho(X \times \{-1\} > 0) \geqslant M. \tag{3.1}$$

De même si $s(x) \leqslant -r$ pour tout $x \in X$,

$$I[s] = \int_Z V(y, s(x))\,\mathrm{d}\rho(x,y) \geqslant \int_{X\times\{1\}} v(1, s(x))\,\mathrm{d}\rho(x,1) \geqslant \frac{M}{\alpha}\rho(X\times\{1\} > 0) \geqslant M. \tag{3.2}$$

Soit $b = s - Qs \in \mathbb{R}$, supposons que $b \geqslant 0$ alors

$$b = \|s - Qs\|_{\mathscr{S}} \geqslant \|s\|_{\mathscr{S}} - \|Qs\|_{\mathscr{S}} \geqslant R - \|Qs\|_{\mathscr{S}}.$$

Par reproduction

$$s(x) = b + Qs = b + \langle Qs, K_x\rangle_{\mathscr{H}} \geqslant b - \|Qs\|_{\mathscr{H}}\|K_x\|_{\mathscr{H}} \geqslant b - C\|Qs\|_{\mathscr{S}} \geqslant R - (1+C)\|Qs\|_{\mathscr{S}}.$$

On voudrait que cette borne soit plus petite que r pour un choix de R.

- Si $\|Qs\|_{\mathscr{S}} \leqslant \dfrac{R}{2(1+C)}$ alors en prenant $R \geqslant 2r$ on a $s(x) \geqslant \dfrac{R}{2} \geqslant r$ donc d'après (3.1) $I[s] + \lambda\|Qs\|^2_{\mathscr{S}} \geqslant M$.
- Si $\|Qs\|_{\mathscr{S}} \geqslant \dfrac{R}{2(1+C)}$ alors $I[s] + \lambda\|Qs\|^2_{\mathscr{S}} \geqslant \lambda\|Qs\|^2_{\mathscr{S}} \geqslant \dfrac{\lambda R^2}{4(1+C)^2}$. En prenant $R \geqslant \dfrac{2(1+C)\sqrt{M}}{\sqrt{\lambda}}$ on a $I[s] + \lambda\|Qs\|^2_{\mathscr{S}} \geqslant \|Qs\|^2_{\mathscr{S}} \geqslant M$.

Finalement en choisissant $R = \max(2r, \dfrac{2(1+C)\sqrt{M}}{\sqrt{\lambda}})$ on obtient le résultat souhaité pour le cas $b \geqslant 0$.

Si maintenant $b \leqslant 0$, alors $-b = \|s - Qs\|_{\mathscr{S}} \geqslant \|s\|_{\mathscr{S}} - \|Qs\|_{\mathscr{S}}$ d'où $b \leqslant -\|s\|_{\mathscr{S}} + \|Qs\|_{\mathscr{S}} \leqslant -R + \|Qs\|_{\mathscr{S}}$. Donc

$$s(x) = b + \langle Qs, K_x\rangle_{\mathscr{H}} \leqslant b + \|Q_s\|_{\mathscr{S}}C \leqslant -R - (1+C)\|Qs\|_{\mathscr{S}}.$$

De la même façon, si $\|Qs\|_{\mathscr{S}} \leqslant \dfrac{R}{2(1+C)}$ alors $s(x) \leqslant -r$ donc d'après (3.2) $I[s] + \lambda\|Qs\|^2_{\mathscr{S}} \geqslant I[s] \geqslant M$. Et si $\|Qs\|_{\mathscr{S}} \geqslant \dfrac{R}{2(1+C)}$ alors $I[s] + \lambda\|Qs\|^2_{\mathscr{S}} \geqslant \|Qs\|^2_{\mathscr{S}} \geqslant M$. Ce qui termine la preuve en appliquant la proposition 1.1.6. □

Proposition 3.0.3

Soit V une fonction de perte p par rapport à ρ avec $p \in [1\,;+\infty[$. Supposons K et $K^{\mathscr{B}}$ p-borné par rapport à ρ et soit $\lambda > 0$.

Soit s^λ une solution de $\min\limits_{s\in\mathscr{S}}(I[s] + \lambda\|Qs\|^2_{\mathscr{S}})$, alors

- si s' est une autre solution alors $Qs^\lambda = Qs'$.
- si $V(y,\cdot)$ est strictement convexe pour tout $y \in Y$ alors tous les minimums sont de la forme $s^\lambda + g$ avec $g \in \mathscr{S}$ telle que $Qg = 0$ et $g(x) = 0$ ρ_X-presque partout.

Démonstration. (i) : Supposons par l'absurde que $Qs^\lambda \neq Qs'$. Par stricte convexité de $\|Q\cdot\|^2_{\mathscr{S}}$ car $Qs^\lambda \neq Qs'$, pour tout $t \in]0\,;1[$,

$$\|(1-t)Qs^\lambda + tQs'\|^2_{\mathscr{S}} < (1-t)\|Qs^\lambda\|^2_{\mathscr{S}} + t\|Qs'\|^2_{\mathscr{S}}$$

Donc par convexité de I

$$\begin{aligned}
I[(1-t)s^\lambda + ts'] + \lambda\|Q((1-t)s^\lambda + ts')\|^2_{\mathscr{S}} &= I[(1-t)s^\lambda + ts'] + \lambda\|(1-t)Qs^\lambda + tQs'\|^2_{\mathscr{S}} \text{ car } Q \text{ est linéaire.}\\
&< (1-t)I[s^\lambda] + tI[s'] + (1-t)\lambda\|Qs^\lambda\|^2_{\mathscr{S}} + t\lambda\|Qs'\|^2_{\mathscr{S}}\\
&= (1-t)[I[s^\lambda] + \lambda\|Qs^\lambda\|^2_{\mathscr{S}}] + t[I[s'] + \lambda\|Qs'\|^2_{\mathscr{S}}]\\
&= \min_{s\in\mathscr{S}} I[s] + \lambda\|Qs\|^2_{\mathscr{S}}
\end{aligned}$$

car s^λ et s' sont des solutions du problème. On a donc trouvé un $s'' \in \mathscr{S}$ tel que $I[s''] + \lambda\|Qs''\|^2_{\mathscr{S}}$ est strictement plus petit que le minimum ce qui est absurde. Donc $Qs^\lambda = Qs'$.

(ii) : Soit s' une solution du problème, alors d'après le point précédent $Qs' = Qs^\lambda$. Posons $g = s' - s^\lambda \in \mathscr{S}$, on

a donc $Qg = 0$. Posons

$$U = \{x \in X \mid g(x) \neq 0\} = \{x \in X \mid s'(x) \neq s^\lambda(x)\}$$

un ensemble mesurable car g mesurable. Supposons par l'absurde que $\rho_X(U) > 0$, c'est à dire $\rho(U \times Y) > 0$. Soit $t \in]0\,;1[$, par strict convexité, $\forall (x\,,y) \in U \times Y$,

$$V(y, (1-t)s^\lambda(x) + ts'(x)) < (1-t)V(y, s^\lambda) + tV(y, s')$$

Or en décomposant sur $U \times Y$ et son complémentaire

$$\begin{aligned}
\int_{X\times Y} V(y, (1-t)s^\lambda(x) + ts'(x))\,\mathrm{d}\rho(x,y) &= \int_{U\times Y} V(y, (1-t)s^\lambda(x) + ts'(x))\,\mathrm{d}\rho(x,y) \\
&\quad + \int_{(U\times Y)^c} V(y, (1-t)s^\lambda(x) + ts'(x))\,\mathrm{d}\rho(x,y) \\
&< (1-t)\int_{U\times Y} V(y, s^\lambda)\,\mathrm{d}\rho(x,y) + t\int_{U\times Y} V(y, s')\,\mathrm{d}\rho(x,y) \\
&\quad + \int_{(U\times Y)^c} V(y, s^\lambda)\,\mathrm{d}\rho(x,y)
\end{aligned}$$

car V est strictement convexe et par égalité de s^λ et s' sur $(U \times Y)^c$

$$\begin{aligned}
&= (1-t)\int_{U\times Y} V(y, s^\lambda)\,\mathrm{d}\rho(x,y) + t\int_{U\times Y} V(y, s')\,\mathrm{d}\rho(x,y) \\
&\quad + (1-t)\int_{(U\times Y)^c} V(y, s^\lambda)\,\mathrm{d}\rho(x,y) + t\int_{(U\times Y)^c} V(y, s')\,\mathrm{d}\rho(x,y)
\end{aligned}$$

en écrivant $V = (1-t)V + tV$ et en remplacant s^λ par s' dans la deuxième intégrale (égalité sur $(U \times Y)^c$)

$$= (1-t)\int_{X\times Y} V(y, s^\lambda)\,\mathrm{d}\rho(x,y) + t\int_{X\times Y} V(y, s')\,\mathrm{d}\rho(x,y).$$

C'est à dire $I[(1-t)s^\lambda + ts'] < (1-t)I[s^\lambda] + tI[s']$. On est de nouveau dans une situation de strict convexité pour le minimum, ce qui est absurde. Donc $\rho_X(U) = 0$. □

Proposition 3.0.4
On se place dans le cas où $Y = \{-1, 1\}$, $\mathscr{B} = \mathbb{R}$ avec $V(y, w) = |1 - yw|_+$ et K est 1-borné. On se donne un jeu de données $S = \{(x_i\,, y_i)\}_{1\leqslant i\leqslant l}$. Soit s^λ la solution de

$$\min_{s\in S} \frac{1}{l}\sum_{i=1}^{l} V(y_i, s(x_i)) + \lambda\|Qs\|^2_{\mathscr{S}}. \tag{3.3}$$

On définit les ensembles

$$\begin{aligned}
L_+ &= \{i \in [1\,;l] \mid y_i = 1, s^\lambda(x_i) < 1\} \quad \text{et} \quad L_- = \{i \in [1\,;l] \mid y_i = -1, s^\lambda(x_i) > -1\} \\
B_+ &= \{i \in [1\,;l] \mid y_i = 1, s^\lambda(x_i) = 1\} \quad \text{et} \quad B_- = \{i \in [1\,;l] \mid y_i = -1, s^\lambda(x_i) = -1\}.
\end{aligned}$$

La solution s^λ est unique si et seulement si $\mathrm{card}(L_+) \neq \mathrm{card}(L_-)+\mathrm{card}(B_-)$ et $\mathrm{card}(L_-) \neq \mathrm{card}(L_+)+\mathrm{card}(B_+)$.

Démonstration. Montrons déjà que ce problème admet effectivement une solution. Le noyau $K^{\mathscr{B}}$ est constant égal à 1 (donc 1-borné). On note ρ_S la probabilité empirique sur S. Alors V est une 1-loss par rapport à ρ_S qui respecte les conditions du théorème 3.0.2.
En effet V est mesurable, $V(\pm, \cdot)$ est convexe et vérifie $V(y, w) \leqslant 1 + |w|$. De plus

$$\lim_{w\to+\infty} V(-1, w) = \lim_{w\to-\infty} V(1, w) = +\infty.$$

Les réels $\rho_S(X \times \{1\})$ et $\rho_S(X \times \{-1\})$ sont non nuls car on suppose qu'il y a au moins un points dans chaque

cluster dans un problème de classification.
Le problème se réécrit donc sous la forme

$$\min_{s\in\mathscr{S}} I[s] + \lambda\|Qs\|^2_{\mathscr{S}}$$

et d'après le théorème 3.0.2 il admet une solution.

Démontrons maintenant le résultat. Soit s' une autre solution de (3.3). D' après 3.0.3 on a $Qs' = Qs^\lambda$ donc $s' = s^\lambda + b$ avec $b \in \mathbb{R}$. Décomposons la somme dans (3.3) :

$$\begin{cases} \text{Si } i \in L_+ \cup L_- \text{ alors } y_i s^\lambda(x_i) < 1 \\ \text{Si } i \in B_+ \cup B_- \text{ alors } y_i s^\lambda(x_i) = 1 \\ \text{Si } i \notin L_+ \cup L_- \cup B_+ \cup B_- \text{ alors } y_i s^\lambda(x_i) > 1 \end{cases}$$

Ainsi on a

$$\begin{aligned} \sum_{i=1}^{l} \big|1 - y_i s^\lambda(x_i)\big|_+ &= \sum_{i\in L_+\cup L_-} \underbrace{\big|1 - y_i s^\lambda(x_i)\big|_+}_{=1-y_i s^\lambda(x_i)} + \sum_{i\in B_+\cup B_-} \underbrace{\big|1 - y_i s^\lambda(x_i)\big|_+}_{=0} + \sum_{i\notin L_+\cup L_-\cup B_+\cup B_-} \underbrace{\big|1 - y_i s^\lambda(x_i)\big|_+}_{=0} \\ &= \sum_{i\in L_+\cup L_-} 1 - y_i s^\lambda(x_i). \end{aligned}$$

De même pour s' on a

$$\begin{cases} \text{Si } i \in L_+ \cup L_- \text{ alors } y_i s'(x_i) \leqslant 1 \\ \text{Si } i \notin L_+ \cup L_- \cup B_+ \cup B_- \text{ alors } y_i s'(x_i) \geqslant 1 \end{cases}$$

En effet supposons qu'il existe $i \in [\![1\,;l]\!]$ tel que $y_i s'(x_i) > 1$, alors

$$V(y_i, (1-t)s^\lambda(x_i) + ts'(x_i)) < (1-t)V(y_i, s^\lambda(x_i)) + tV(y_i, s'(x_i))$$

pour $t \in]0\,;1[$ car on a simultanément $y_i s'(x_i) > 1$ et $y_i s^\lambda(x_i) < 1$ (on a une strict convexité car on est sur deux morceaux affines différent). Mais alors en sommant sur tous les indices (on rappelle que la fonction est convexe non strictement pour les autres points) on obtient

$$\sum_{i=1}^{l} V(y_i, (1-t)s^\lambda(x_i) + ts'(x_i)) < (1-t)\sum_{i=1}^{l} V(y_i, s^\lambda(x_i)) + t\sum_{i=1}^{l} V(y_i, s'(x_i)).$$

C'est à dire en rajoutant le terme de norme en se souvenement que la norme est convexe,

$$I[(1-t)s^\lambda + ts'] + \lambda\big\|Q((1-t)s^\lambda + ts')\big\|^2_{\mathscr{S}} < \min_{s\in S} \frac{1}{l}\sum_{i=1}^{l} V(y_i, s(x_i)) + \lambda\|Qs\|^2_{\mathscr{S}}$$

car s' et s^λ sont solution de (3.3). On obtient donc une nouvelle solution strictement plus petite ce qui est impossible, donc $\forall i \in [\![1\,;l]\!]$, $y_i s'(x_i) \leqslant 1$. Le deuxième cas se traite de la même façon. Ainsi

$$\begin{aligned} \sum_{i=1}^{l} |1 - y_i s'(x_i)|_+ &= \sum_{i\in L_+\cup L_-} \underbrace{|1 - y_i s'(x_i)|_+}_{=1-y_i s'(x_i)} + \sum_{i\in B_+\cup B_-} \underbrace{|1 - y_i s'(x_i)|_+}_{=|-by_i|_+} + \sum_{i\notin L_+\cup L_-\cup B_+\cup B_-} \underbrace{|1 - y_i s'(x_i)|_+}_{=0} \\ &= \sum_{i\in L_+\cup L_-} 1 - y_i s'(x_i) + \sum_{i\in B_+\cup B_-} |-by_i|_+. \end{aligned}$$

Et comme s^λ et s' sont tous les deux solutions de (3.3) on obtient finalement l'égalité

$$\begin{aligned}
&\sum_{i=1}^{l}\big|1-y_i s^\lambda(x_i)\big|_+ = \sum_{i=1}^{l}|1-y_i s'(x_i)|_+ \\
\iff &\sum_{i\in L_+\cup L_-} 1-y_i s^\lambda(x_i) = \sum_{i\in L_+\cup L_-} 1-y_i s'(x_i) + \sum_{i\in B_+\cup B_-} |-by_i|_+ \\
\iff &\sum_{i\in L_+\cup L_-} y_i(s'(x_i)-s^\lambda(x_i)) = \sum_{i\in L_+\cup L_-} by_i = \sum_{i\in B_+\cup B_-} |-by_i|_+.
\end{aligned}$$

- Si $b>0$ alors b est solution si et seulement si

$$\begin{aligned}
&\sum_{i\in L_+\cup L_-} by_i = \sum_{i\in B_+\cup B_-} by_i \\
\iff &\sum_{i\in L_+} b + \sum_{i\in L_-} -b = 0 + \sum_{i\in B_-} b \\
\iff &\operatorname{card}(L_-)+\operatorname{card}(B_-) = \operatorname{card}(L_+).
\end{aligned}$$

- De même si $b<0$ alors b est solution si et seulement si $\operatorname{card}(L_+)+\operatorname{card}(B_+) = \operatorname{card}(L_-)$.

Finalement l'équation en b possède une solution non nulle si et seulement si

$$\begin{aligned}
\operatorname{card}(L_-)+\operatorname{card}(B_-) = \operatorname{card}(L_+) \text{ et } b>0 \\
\operatorname{card}(L_+)+\operatorname{card}(B_+) = \operatorname{card}(L_-) \text{ et } b<0.
\end{aligned} \tag{3.4}$$

Donc si on a ni la première ni la deuxième égalité de (3.4) alors $b=0$ c'est à dire $s^\lambda = s'$. □

Théorème 3.0.5

On termine en énoncant le cas particulier du Support Vector Machines (SVM) pour la classification avec la distribution empirique donnée à la fin de [DV]. On se place dans le cas $\mathscr{B}=\mathbb{R}$ avec la mesure empirique ρ_S. Soit $\lambda>0$ alors

$$(f^\lambda, b^\lambda) \in \operatorname{argmin}_{(f,b)\in\mathscr{H}\times\mathbb{R}} \frac{1}{l}\sum_{i=1}^{l} V(y_i, f(x_i)+b) + \lambda\|f\|^2_{\mathscr{H}}$$

si et seulement si

$$s^\lambda := f^\lambda + b^\lambda \in \operatorname{argmin}_{s\in\mathscr{H}+\mathbb{R}} \frac{1}{l}\sum_{i=1}^{l} V(y_i, s(x_i)) + \lambda\|Qs\|^2_{\mathscr{H}} \quad \text{et} \quad f^\lambda = Qs^\lambda$$

si et seulement si il existe $(\alpha_i)_{1\leqslant i\leqslant l}\in\mathbb{R}^l$ telle que

- $$f^\lambda = \sum_{i=1}^{l}\alpha_i K_{x_i} = \sum_{i=1}^{l}\alpha_i(K_{x_i}+1)$$
- $$-\frac{1}{2\lambda l}V'_+(y_i, f^\lambda(x_i)+b^\lambda) \leqslant \alpha_i \leqslant -\frac{1}{2\lambda l}V'_-(y_i, f^\lambda(x_i)+b^\lambda)$$
- $$\sum_{i=1}^{l}\alpha_i = 0.$$

Ce sont l'analogue des conditions de KKT.

En se placant dans le cadre de la proposition 3.0.4, la solution est donnée par $s^\lambda = \sum_{i=1}^{l}\alpha_i y_i K_{x_i} + b^\lambda$ avec $(\alpha_i)_{1\leqslant i\leqslant l}$ solution de

- $$0 \leqslant \alpha_i \leqslant \frac{1}{2\lambda l} \text{ si } y_i(\sum_{j=1}^{l} \alpha_j y_j K(x_i, x_j) + b^\lambda) = 1$$
- $$\alpha_i = 0 \text{ si } y_i(\sum_{j=1}^{l} \alpha_j y_j K(x_i, x_j) + b^\lambda) > 1$$
- $$\alpha_i = C\frac{1}{2\lambda l} \text{ si } y_i(\sum_{j=1}^{l} \alpha_j y_j K(x_i, x_j) + b^\lambda) < 1$$
- $$\sum_{i=1}^{l} \alpha_i y_i = 0$$

Conclusion

Nous avons dans ce rapport étudié de manière théorique la structure des solutions de problème de régularisation à noyau régularisant. On a fournit une caractérisation à base de sous gradient pour la formulation dans $\mathscr{H} \times \mathscr{B}$ avec des fonctions de pertes convexes et un espace d'offset ; en analogie au representer theorem dans le cadre classique des noyau régularisant. Puis nous avons relié ce résultat à une régularisation sur l'espace somme $\mathscr{H} + \mathscr{B}$ bien plus naturel, c'est un espace de fonctions et un RKHS et nous avons étudié quelques cas d'existence et d'unicité.

Comme anoncé dans l'abstract, la force du papier est l'unification et la généralisation des problèmes de régularisation. L'ajout d'un espace d'offset permet de tenir compte de contrainte libre dans notre problème et le choix d'utiliser la véritable mesure de nos données (qui est inconnue) plutôt que la mesure empirique permet d'englober l'étude du risque empirique dans le cadre général, ne devenant que le cas particulier où $\rho = \rho_S$ et permet d'établir des résultats de régularisation sur la vrai distribution de données plutôt qu'un échantillon qui fluctue.
On n'impose pas de condition de compacité sur les espaces input et output si bien que l'espace des output peut aussi bien être $\mathbb{R}$ (régression) que $\{\pm 1\}$ (classification). Le fait de ne pas imposé non plus des fonctions de pertes différentiables permet d'étendre les résultats à des fonctions de perte classique en pratique (hinge loss) et de formuler des résultats analogue au representer theorem dans le cadre des noyaux régularisants avec le sous gradient.

Pendant tout le rapport nous n'avons cessé de rappelé les différentes hypothèses des résultats énoncés pour insister sur le cadre dans lequel est écrit l'article. En particulier les hypothèses p-loss et p-bornée sont indispensables car elles assurent notamment l'inclusion de $\mathscr{H}$ dans l'espace $L^p(Z, \rho)$ ce qui permet d'exprimer le problème de régularisation avec la fonciton de Nemitski et d'utiliser les différents outils de l'analyse convexe mais aussi d'assurer la continuité de la fonction de Nemitski.
Ces hypothèses qui pourraient donc fournir des sources naturelles d'amélioration. Même si dans la plupart des problèmes ces hypothèses sont raisonnables, elles sont vérifiés dans les cas classiques de régression et classification, elles ne peuvent s'étendre à des cas où les inputs sont non compact (localement) ou des noyaux non bornés, ce qui dans la théorie plus que la pratique est restrictif.
Une vrai limitation est l'équivalence entre $\mathscr{H} \times \mathscr{B}$ et $\mathscr{H} + \mathscr{B}$ car comme on l'a vu elle n'est pas toujours garantie.
Il est à noté que le papier fournit des conditions pour le problème de régularisation mais pas de solution explicite exploitable algorithmiquement. L'apport du papier est surtout théorique et les méthodes classiques de résolution algorithmique seront toujours privilégiées dans la pratique.
Une piste pour généraliser les résultats serait (je pense) de sortir du cadre des espaces de Hilbert pour se placer dans un espace de Banach quelconque et de regarder les problèmes de régularisation avec des termes de lissage qui ne serait plus forcément quadratique. Les différents résultats sur les sous-gradient restent vrai dans un espace de Banach, ce qui motiverait cette étude.

Pour résumer, la force de cet article est avant tout dans sa portée unificatrice et dans l'apport d'un cadre théorique solide de l'étude des noyaux régularisants plutôt que dans un apport pratique ou d'algorithme.

Bibliographie

[DV] De Vito, E., Rosasco, L., Caponnetto, A., Piana, M., Verri, A. *Some Properties of Regularized Kernel Methods.* Journal of Machine Learning Research 5, 2004, 1363-1390.

[ETu] Ekeland, I., Turnbull, T. *Infinite-dimensional Optimization and Convexity.* Chicago Lectures in Mathematics. University of Chicago Press, Chicago and London, 1983.

[ETe] Ekeland, I., Teman, R. *Analyse convexe et problèmes variationnels. Etudes mathématiques.* Dunod, 1974.

[Li] Li, D. *Cours d'analyse fonctionnelle - avec 200 exercices corrigés.* Editions Ellipses, 2013.